


Reconstructing QRS Complex From PPG by Transformed Attentional Neural Networks

Presentation : Lee Jeong-Hwi

Contents

1. Introduction
2. Related Work
3. Background
4. Method
5. Result
6. Implementation

Introduction



<사망원인 순위 추이>
(단위: 인구 10만 명당 명)

순위	사망원인	사망률	'19년 순위 대비
1	악성신생물(암)	160.1	-
2	심장 질환	63.0	-
3	폐렴	43.3	-
4	뇌혈관 질환	42.6	-
5	고의적 자해(자살)	25.7	-
6	당뇨병	16.5	-
7	알츠하이머병	14.7	-
8	간 질환	13.6	-
9	고혈압성 질환	11.9	↑(+1)
10	패혈증	11.9	↑(+1)



ECG 신호의 중요성이 높아짐

PPG

Pros

- 측정하기 편함
- 가격대가 저렴함

Cons

- 심박수 측정에 적합 (HRV는 불가)
- 의학진단에 있어서 신뢰도가 낮음

ECG

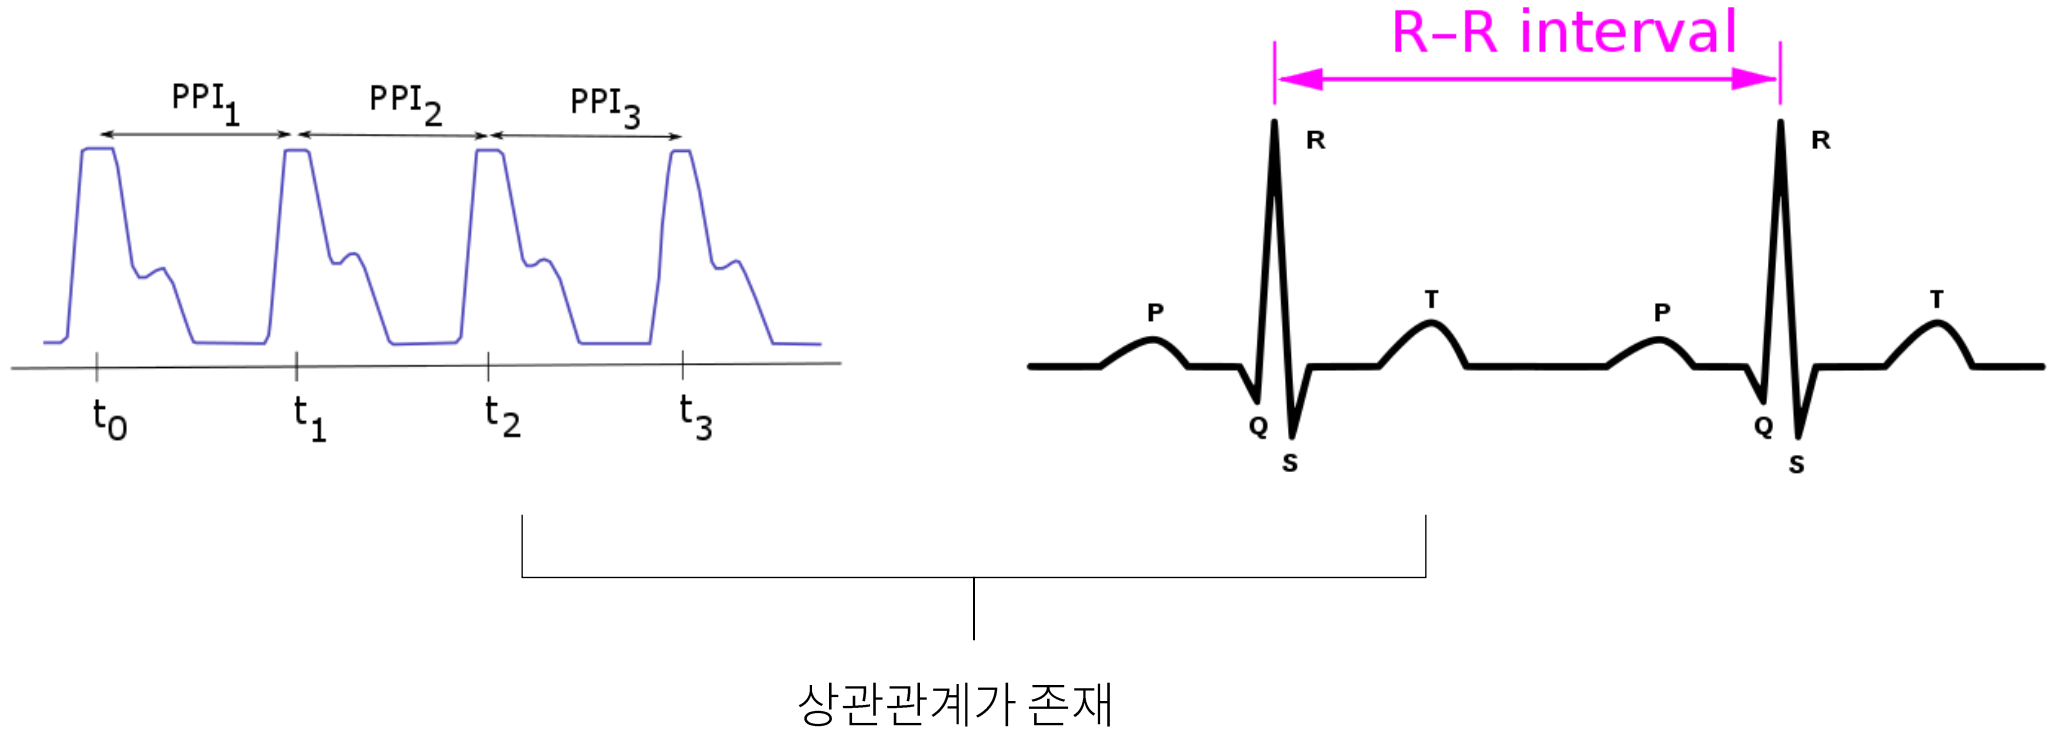
Pros

- 많은 연구와 자료들이 존재
- HRV 측정 가능

Cons

- 측정하기 불편함
- 운동 중 측정이 어려움

Introduction



PPG에서 ECG를 도출하는 것이 가능하다고 판단

CNN Based Encoder Decoder Architecture

1. CNN은 병렬계산 가능

2. Encoder-Decoder 구조 { Domain Adaption [9]
Signal Denoising [10]-[12] 에 효과적임을 입증
Anomaly Detection [10]

[9] M. Chen, Z. Xu, K. Q. Weinberger, and F. Sha, "Marginalized denoising autoencoders for domain adaptation," in International Conference on Machine Learning (ICML), Jun 2012.

[10] M. Sakurada and T. Yairi, "Anomaly detection using autoencoders with nonlinear dimensionality reduction," in Workshop on Machine Learning for Sensory Data Analysis (MLSDA), Dec 2014.

[11] G. Litjens, T. Kooi, B. E. Bejnordi, A. A. A. Setio, F. Ciompi, M. Ghafoorian, J. A. van der Laak, B. van Ginneken, and C. I. S'anchez, "A survey on deep learning in medical image analysis," Medical Image Analysis, vol. 42, p. 60–88, Dec 2017.

[12] S. M. Erfani, S. Rajasegarar, S. Karunasekera, and C. Leckie, "Highdimensional and large-scale anomaly detection using a linear one-class svm with deep learning," Pattern Recognition, vol. 58, pp. 121–134, Oct 2016.

1. PhotoECG

- PPG Features를 사용하여 ECG의 매개변수의 범위를 추정하기 위한 기계학습 기반 Feature Selection 알고리즘
 - PPG Features (15개)를 사용하여 ECG의 매개변수 범위를 추정
 - MIC (Maximum Information Coefficient) 방법을 사용하여 Feature Selection 알고리즘 수행
> 관련성에 따라 PPG의 Feature 순위를 지정
 - 노이즈가 많은 PPG에서 outlier Feature를 제거하여 성능을 향상시킴

ECG의 매개변수

- PR Interval
- QRS Interval
- QT interval
- RR interval




Fig. 4. Performance of ECG classifiers for different values of k for the two datasets.




Fig. 1. (a) Sample PPG signal with 3 full cycles and its (b) frequency components.



ECG파형을 완벽히 재구성하지 못한다면 다양한 시스템에 사용이 어려움

2. PPG 주기의 DCT 변환계수를 ECG 주기의 계수로 맵핑하여 ECG 파형을 재구성

- ECG와 PPG의 신호 쌍을 전처리 → 시간이 맞춰지고 정규화된 신호를 획득
- 정규화된 신호 쌍을 분할시켜서 PPG 주기의 DCT 계수를 ECG 주기의 계수로 맵핑
- DCT계수가 맵핑된 ECG 주기에 역DCT를 통해서 ECG 파형을 얻음

※ DCT : Discrete Cosine Transform

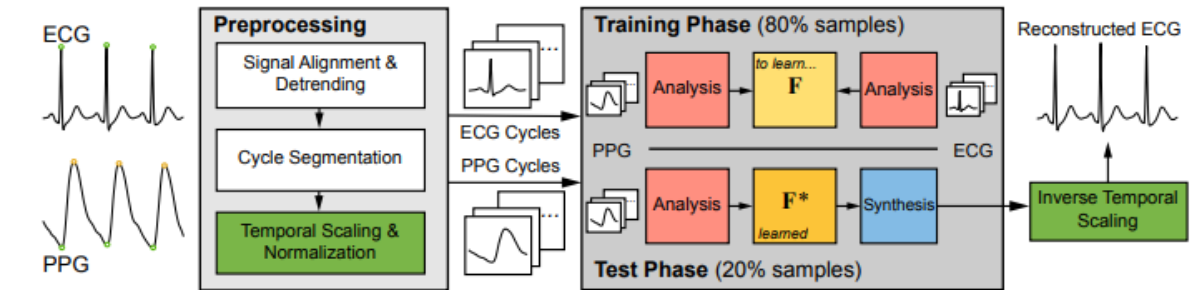




Fig. 3. Flowchart of the proposed system. The ECG and PPG signals are first preprocessed to obtain physically aligned and normalized pairs of cycles. The selected DCT coefficients of 80% pairs of cycles are used for training a linear transform F which is used in the test phase to reconstruct the ECG signals.



전처리 단계에서 PTT, HRV와 같은 Temporal information 을 잃게되기 때문에 좋은 방법이 아님
그리고 전처리 오버헤드가 발생할 수 있는 위험이 있어 실시간 변환이 어렵다고 함

Background

ECG



R Peak : ECG 신호 중 가장 높은 지점


Magnitude : 신호의 크기

Phase : 주기의 시작

Background

Encoder-Decoder

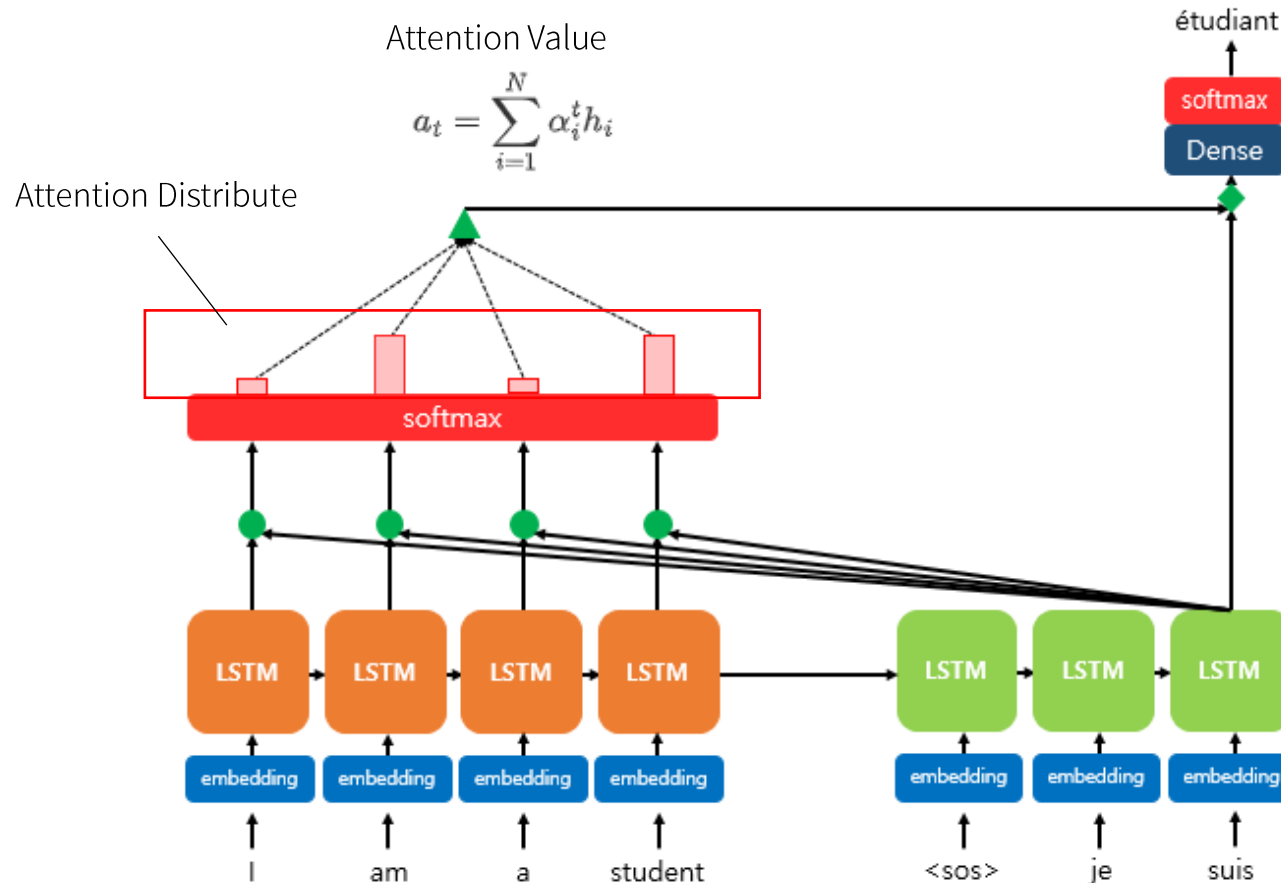
- 전체 입력 문장을 하나의 벡터로 **압축** 시키고(encoder), 압축된 내용을 **복원**시키는(Decoder) 구조
 - 입력값에 대한 정보를 잘 압축시키는 것이 encoder의 목표



Background

Attention Network

- 딥러닝 모델이 특정 벡터에 주목(Attention) 하게 만들어 모델의 성능을 높이는 기법



- h_i = 인코딩과정에서 생긴 Hidden State
- α_i^t = 디코딩과정에서 생긴 Hidden state와 h_i 를 곱하여 생긴 벡터를 softmax 한 값
- a_t = Attention Value

Method

Proposal Model Architecture

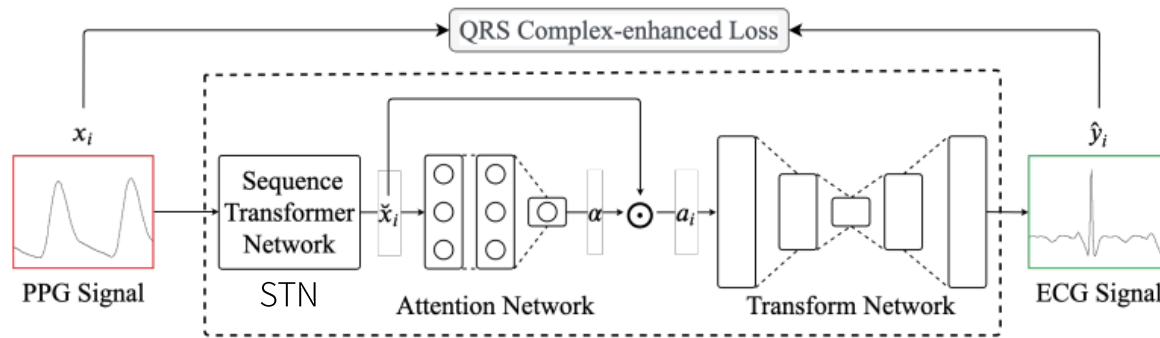


Fig. 1. The architecture of the proposed method.

- 오프셋을 자동적으로 보정해주는 Sequence Transformer Network
- 동적으로 ROI를 식별하는 Attention Network
- 재구성하는데 더 효과적인 QRS Complex-enhanced Loss

$$\text{PPG} : x_i = (x_{i,1}, \dots, x_{i,t}, \dots, x_{i,T_i})$$

$$\text{ECG} : y_i = (y_{i,1}, \dots, y_{i,t}, \dots, y_{i,T_i})$$

x_i 를 y_i 에 근접한 \hat{y}_i 로 변환하는 것을 목표로 함

$i = \text{user}, T_i = \text{Time steps}$

Method - STN

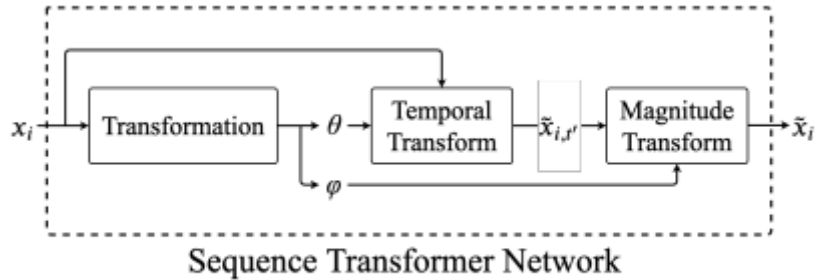


Fig. 2. The architecture of the Sequence Transformer Network.

STN

시간 차원에 따라 데이터를 변환

입력데이터에서 값을 가져와서 새로운 시간 위치에 매핑하는 네트워크 [22]

phase

$$t' = \theta \begin{bmatrix} t \\ 1 \end{bmatrix} = [\theta_1 \quad \theta_0] \begin{bmatrix} t \\ 1 \end{bmatrix}.$$

- t' = 변환된 시간점
- t = 기존 시간점
- Θ = 위상에 관련된 매개변수, 세타를 사용하여 phase(위상) 변환

$$t' = \theta_1 t + \theta_0 \quad \text{변환된 시간축 (index)}$$

$$x_{i,t} \text{의 시간축을 변형시키고 새로운 시공간에 맵핑 된 값} = \tilde{x}_{i,t'} = x_{i,(\theta_1 t + \theta_0)} \quad \text{위상 변환된 값}$$

magnitude

$$\check{x}_{i,t} = \phi \begin{bmatrix} \tilde{x}_{i,t} \\ 1 \end{bmatrix} = [\phi_1 \quad \phi_0] \begin{bmatrix} \tilde{x}_{i,t} \\ 1 \end{bmatrix}$$

$\tilde{x}_{i,t}$ = 시간 t에 대한 시간 변환된 값

ϕ = 크기에 대한 매개변수 값

$$\check{x}_{i,t} = \phi_1 \tilde{x}_{i,t} + \phi_0 \quad \tilde{x}_{i,t} \text{의 크기를 시간 t에서 } \check{x} \text{에 맵핑하여 크기를 shift, scale 있도록 하는 식}$$

$$\check{x}_i = STN(x_i)$$

Method - Attention


Inner Attention Network^[23]

Attention before representation

- PPG의 중요한 부분을 학습하는데 사용함 → 인풋에서 더 중요한 곳을 찾기 위해 Inner Attention 을 사용했다고함

기존 Attention과의 차이점

- 기존 Attention은 Encoder를 거쳐서 생긴 Context Vector를 기반으로 Decoder의 Hidden state와 product를 수행
- Inner Attention은 encoding 하기 전 x에 대한 attention value를 곱해주고 곱해준 값을 encoder-decoder(transform network)에 전달



Method - Loss

L_1 loss function

$$L_1 = \sum_{i \in N} |y_i - \hat{y}_i|. \quad = \text{일반적인 절대오차의 합을 가리킴}$$

- 재구성된 ECG에서 R Peak는 실제 값보다 작은 경향이 있음 \rightarrow R Peak 검출 실패
 - R Peak의 위치가 약간만 어긋나도 L_1 loss 가 크게 증가하게 되서 R Peak의 Magnitude가 작아짐

proposed loss function (QRS complex-enhanced Loss)

$$L_{QRS} = \sum_{i=1}^N \sum_{t=1}^T |y_{i,t} - \hat{y}_{i,t}| \left(1 + \beta \sum_{k=1}^{K_i} e^{-\frac{(t - c_{i,k})^2}{2\sigma^2}} \right),$$

K_i = R Peak의 개수

$c_i = (c_{i,1}, c_{i,k}, c_{i,K_i})$ = R Peak의 index \rightarrow i번 user의 k번째 R Peak index를 가리킴


β = 가우스 가중치 함수의 영향을 제어하는 하이퍼 파라미터

- 가우시안 가중치 함수를 사용해서 QRS Complex 영역에 집중하도록 함
 - R Peak의 index를 평균으로 사용하고, hyper parameter σ 를 분산으로 하는 가우스 가중치 함수
- hyper parameter는 σ, β 를 사용

\longrightarrow Biosppy python 패키지에 있는 Hamilton Segmenter 를 사용해서 R Peak 위치 탐색


Results - Dataset

UQVSD The University of Queensland Vital Signs Dataset



마취 받은 32명의 수술 환자로 부터 얻은 데이터셋
Sampling Rate 125Hz
따라서 주로 **정상 심박수**이다
앞단, 끝단에서 발생한 동잡음을 필터링함

BIDMC PPG and Repiration Dataset



중환자 53명의 데이터 (8분) , Sampling Rate 125Hz

PPG, ECG 파형이 UQVSD와 다름

좀 더 **노이즈가 많음**

BIDMC Dataset은 Robust, 일반화를 검증하기 위해 사용함

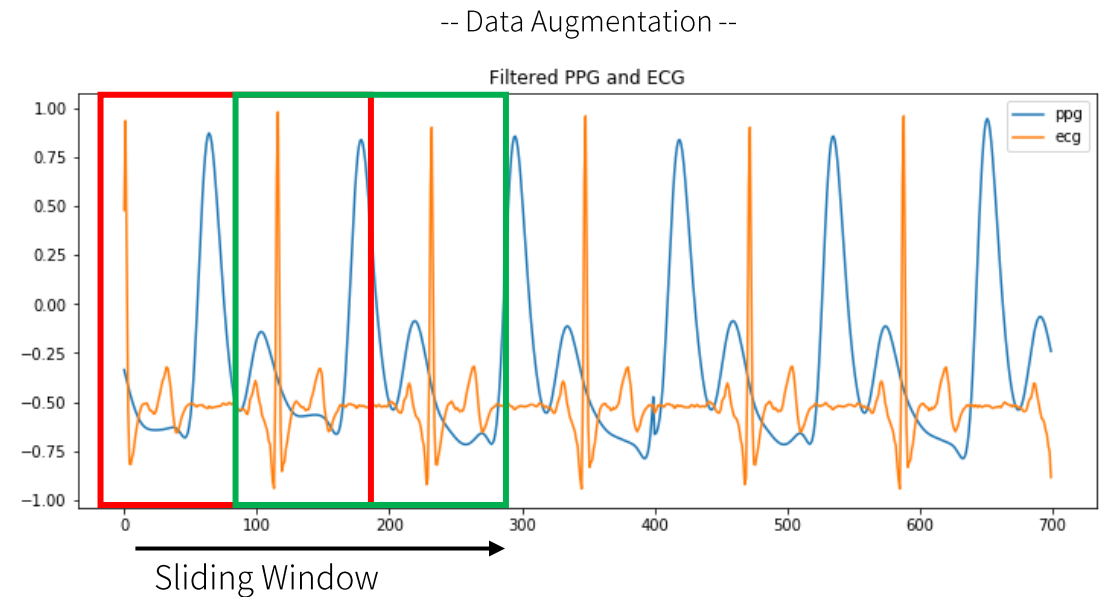
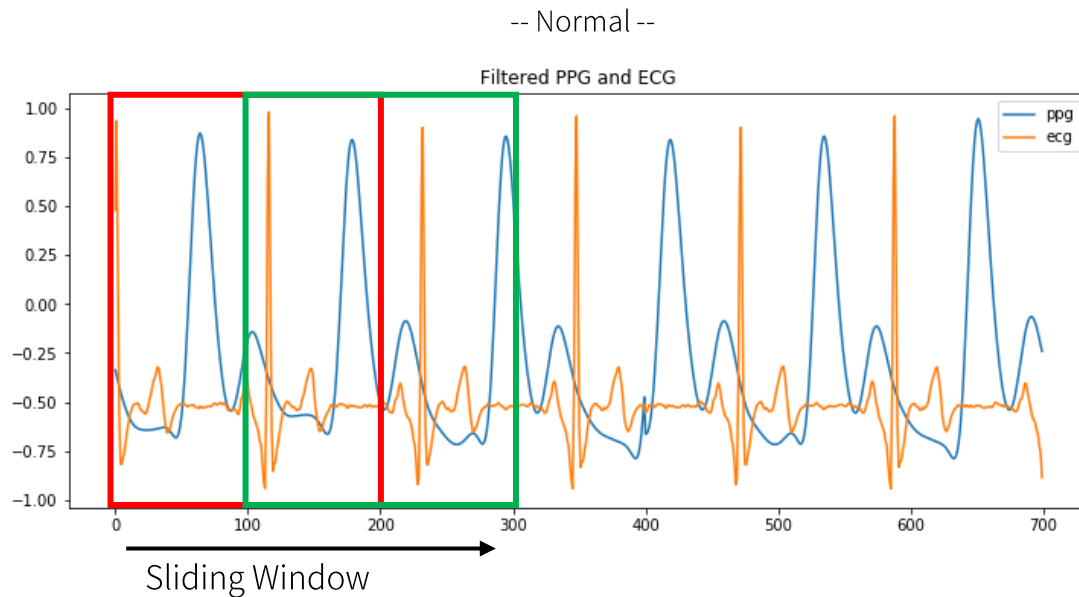
[20] L. D., G. M., and Jenkins, "The university of queensland vital signs dataset: Development of an accessible repository of anesthesia patient monitoring data for research," Anesthesia & Analgesia, vol. 114, pp. 584–589, Dec. 2012.

[21] M. A. F. Pimentel, A. E. W. Johnson, P. H. Charlton, D. Birrenkott, P. J. Watkinson, L. Tarassenko, and D. A. Clifton, "Toward a robust estimation of respiratory rate from pulse oximeters," IEEE Transactions on Biomedical Engineering, vol. 64, pp. 1914–1923, Aug 2017.

Results - Dataset

Data Augmentation

- PPG,ECG의 위상을 무작위로 옮겨서 모델 훈련
- Sliding Window에 걸치는 R Peak가 있을 때의 문제를 완화시키기 위함



Results - Metrics

총 7가지의 평가지표를 사용

L1 QRS – Loss of QRS Complex Area

➔ [-50ms , 70ms] 범위를 QRS Complex Area라고 지정^[30]

L1n QRS – Loss of non-QRS Complex Area

NMAE – Normalized Mean Absoulte Error

NRMSE – Normalized Root Mean Square Error

} 전체 성능 평가 지표

MLE (Mean Location Error) : GroundTruth ECG와 재구성된 ECG사이의 R Peak 위치 차이의 평균

MME (Mean Magnitude Error) : GroundTruth ECG와 재구성된 ECG사이의 R Peak 크기 차이의 평균

R_{FAIL} (R Peak Failure Rate) : 전체 R Peak중 찾지 못한 갯수의 확률

$$R_{FAIL} = \frac{\text{failed R peak detection}}{\text{all R peaks in groundtruth signals}}.$$

Results - Metrics

MLE (Mean Location Error) : GroundTruth ECG와 재구성된 ECG사이의 R Peak 위치 차이의 평균

$$\text{MLE} = \frac{1}{|D_{test}|} \frac{1}{K_i} \sum_{(x_i, y_i) \in D_{test}} \sum_{k=1}^{K_i} f(c_{i,k}, \hat{c}_{i,k}),$$
$$f(c_{i,k}, \hat{c}_{i,k}) = \begin{cases} |c_{i,k} - \hat{c}_{i,k}| & \text{if } |c_{i,k} - \hat{c}_{i,k}| < 10 \\ 10 & \text{otherwise.} \end{cases}$$

MME (Mean Magnitude Error) : GroundTruth ECG와 재구성된 ECG사이의 R Peak 크기 차이의 평균

$$\text{MME} = \frac{1}{|D_{test}|} \frac{1}{K_i} \sum_{(x_i, y_i) \in D_{test}} \sum_{k=1}^{K_i} |y_{i,c_{i,k}} - \hat{y}_{i,c_{i,k}}|.$$

※ $c_i = (c_{i,1}, c_{i,k}, c_{i,K_i})$ = R Peak의 index

$\hat{c}_{i,k}$ = r peak index와 가까운 예측 y값의 r peak position을 의미

Results

UQVSD Dataset 에서의 LSTM과의 비교 결과

THE PERFORMANCE COMPARISON FOR THE UQVID DATASET.

Model	$L1_{QRS}$	$L1_{nQRS}$	MLE	MME	R_{FAIL}	NMAE	NRMSE
Vanilla LSTM	0.3421	0.0688	1.927	0.343	6.66%	0.2741	0.1081
Ours	0.3390	0.0524	1.611	0.118	3.67%	0.2382	0.1070

저자가 제안한 L_{QRS} , STN, Attention 을 제외한 LSTM 만으로 구성된 모델보다 전반적으로 성능이 좋음을 알 수 있음

$L1_{QRS}$ 보다 $L1_{nQRS}$ 의 결과가 더 작은 이유는 non-Complex Area가 좀 더 일정한 값을 가지고 있기 때문

COMPARISONS OF RUNNING TIME WITH DIFFERENT BATCH SIZES.

Model	#Parameters	1	10	100
Vanilla LSTM	10.6M	1.513ms	1.559ms	2.502ms
Ours	10.8M	1.514ms	1.546ms	2.054ms

LSTM의 경우 순차적으로 처리하기 때문에 처리 시간이 더 느림

Convolution의 경우 병렬로 계산이 가능하기 때문에 더 빠름

Results

UQVSD Dataset의 hyper-parameter(σ, β) 에 따른 결과

$$L_{QRS} = \sum_{i=1}^N \sum_{t=1}^T |y_{i,t} - \hat{y}_{i,t}| (1 + \beta \sum_{k=1}^{K_i} e^{-\frac{(t - c_{i,k})^2}{2\sigma^2}}),$$

PERFORMANCES EVALUATION WITH DIFFERENT σ OF THE UQVSD DATASET. NOTE THAT THE VALUE IN THE BRACKET REPRESENTS THE VARIANCE.

σ	MLE	MME	R_{FAIL}
1	1.641 (5.121)	0.111 (0.015)	3.82%
3	1.665 (5.365)	0.172 (0.022)	4.27%
5	1.683 (5.417)	0.182 (0.023)	4.39%
7	1.656 (5.349)	0.190 (0.024)	4.31%

PERFORMANCES EVALUATION WITH DIFFERENT β OF THE UQVSD DATASET. NOTE THAT THE VALUE IN THE BRACKET REPRESENTS THE VARIANCE.

β	MLE	MME	R_{FAIL}
0	1.690 (5.572)	0.209 (0.027)	5.05%
0.1	1.632 (5.086)	0.109 (0.014)	3.84%
0.5	1.616 (5.074)	0.109 (0.014)	3.75%
1	1.633 (5.224)	0.110 (0.015)	4.02%
10	1.630 (5.193)	0.111 (0.014)	4.05%

위 파라미터들은 L_{QRS} 에 영향을 주는 파라미터

σ, β 가 각각 1, 0.5 일때 가장 좋은 성능

Results

STN, Attention, L_{QRS} 유무에 따른 결과

ABLATION STUDY IN TEST SET OF THE UQVID DATASET. NOTE THAT THE VALUE IN THE BRACKET REPRESENTS THE VARIANCE.

Vanilla LSTM	STN	Attention	L_{QRS}	MLE	relative MLE	MME	relative MME	R_{FAIL}
	✓	✓	✓	1.611 (5.059)	+0.00%	0.118 (0.016)	+3.51%	3.67%
	✓	✓		1.620 (5.149)	+0.56%	0.208 (0.028)	+82.46%	4.49%
	✓			1.648 (5.325)	+2.30%	0.221 (0.030)	+93.86%	4.59%
				1.690 (5.572)	+4.90%	0.209 (0.027)	+83.33%	5.05%
		✓	✓	1.624 (5.228)	+0.81%	0.114 (0.016)	+0.00%	3.75%
	✓		✓	1.631 (5.111)	+1.24%	0.117 (0.016)	+2.63%	4.04%
		✓		1.656 (5.522)	+2.79%	0.210 (0.028)	+84.21%	4.96%
			✓	1.657 (5.214)	+2.86%	0.116 (0.016)	+1.75%	3.91%

- STN을 쓰지 않는 경우, MLE, MLE 분산이 증가하여 R Peak Failure가 증가함
- Attention은 R Peak 위치에 더 영향을 주는 것을 알 수 있음 (Vanilla LSTM과의 비교)
- QRS complex-enhanced Loss는 MME를 낮추는데 사용됨을 알 수 있음

Results

Data Augmentation 유무의 차이

IMPROVEMENT BY DATA AUGMENTATION OF THE UQVSD DATASET.
NOTE THAT THE VALUE IN THE BRACKET REPRESENTS THE VARIANCE.

Model	MLE	MME	R_{FAIL}
Ours	1.611 (5.059)	0.118 (0.016)	3.67%
Ours w/o DA	1.828 (5.978)	0.121 (0.022)	4.45%

Data Augmentation을 통해 윈도우 경계에 걸쳐있는 R Peak에 대한 학습도 하기 때문에 MLE를 감소시킴

BIDMC 데이터셋과의 비교

THE PERFORMANCE COMPARISON ON THE UQVID AND BIDMC DATASETS.

Dataset	$L1_{QRS}$	$L1_{nQRS}$	MLE	MME	R_{FAIL}
UQVSD	0.3390	0.0688	1.611	0.118	3.67%
BIDMC	0.3202	0.0386	1.667	0.108	4.37%

BIDMC의 데이터셋이 좀 더 노이즈가 많기에 R FAIL이 증가하였지만 증가폭이 작음을 알 수 있음

Results

Possible Application




Fig. 5. The pulse transit time from the groundtruth signals and reconstructed signals in the UQVSD dataset.

실제 ECG 신호와 재구성된 ECG신호의 PTT 차이는 약 10ms
PPG Peak가 ECG 의 RR interval의 80% 위치에 있음을 보여줌^[37]
→ 따라서 480ms ~ 800ms 범위 내의 PTT 값을 필터링하였음
총 5483개의 R Peak 중 323개의 탐지 실패한 PTT가 있음





Fig. 6. The scatter plot illustrates the relationship between pulse transit time calculated from the groundtruth and from the reconstructed ECG in the UQVSD dataset.

피어슨 상관계수 $\rho = 0.844$
이는 재구성된 ECG가 기존 ECG의 PTT가 유사함을 나타냄
PTT의 대부분이 550ms ~ 750ms에 떨어짐

Implementation

```
uq_vsd_case01_fulldata_12_02.npy
uq_vsd_case01_fulldata_12_03.npy
uq_vsd_case01_fulldata_12_04.npy
uq_vsd_case01_fulldata_12_05.npy
uq_vsd_case01_fulldata_12_06.npy
uq_vsd_case01_fulldata_12_07.npy
uq_vsd_case01_fulldata_12_08.npy
uq_vsd_case01_fulldata_12_09.npy
uq_vsd_case01_fulldata_12_10.npy
uq_vsd_case01_fulldata_12_11.npy
uq_vsd_case01_fulldata_12_12.npy
uq_vsd_case01_fulldata_12_13.npy
uq_vsd_case01_fulldata_12_14.npy
uq_vsd_case01_fulldata_12_15.npy
```




Implementation

```
df = pd.DataFrame()
df["R_ECG"] = reconstruct_ECG
df["G_ECG"] = ecg[50:-50]


fig = px.line(df, title="Reconstructed ECG")
fig.show()
```

1200 1100

Reconstructed ECG (not zoom)



Reconstructed ECG (zoom)



감사합니다!